

Sistemas lineales sobredeterminados

Transparencias basadas en el libro *Computing: An Introductory Survey* by Michael T. Heath, copyright © 2018 by the Society for Industrial and Applied Mathematics. <http://www.siam.org/books/cl80>

Mínimos cuadrados lineales

Método de mínimos cuadrados

- ▶ Los errores de medición y otras fuentes de variación aleatoria son inevitables en las ciencias experimentales.
- ▶ Dicha variabilidad se puede suavizar promediando muchos casos, por ejemplo, tomando más medidas de las estrictamente necesarias para determinar los parámetros del sistema.
- ▶ El sistema resultante está sobredeterminado, por lo que normalmente no hay una solución exacta
Los datos de dimensiones superiores se proyectan en un
- ▶ espacio de dimensiones inferiores para suprimir el ruido o los detalles irrelevantes.
- ▶ Tal proyección la calculamos por el método de mínimos cuadrados

Mínimos cuadrados lineales

- ▶ En problemas lineales obtenemos un sistema lineal **sobredeterminado** $\mathbf{Ax} = \mathbf{b}$, con \mathbf{A} una matriz $m \times n$, $m > n$
- ▶ El sistema es más correcto poner $\mathbf{Ax} \cong \mathbf{b}$, dado que la igualdad no se suele satisfacer cuando $m > n$
- ▶ La solución de mínimos cuadrados \mathbf{x} minimiza la norma Euclidea del vector $\mathbf{r} = \mathbf{b} - \mathbf{Ax}$,

$$\min_{\mathbf{x}} \|\mathbf{r}\|_2^2 = \min_{\mathbf{x}} \|\mathbf{b} - \mathbf{Ax}\|_2^2$$

Ajuste de datos

- ▶ Dados m datos (t_i, y_i) , debemos encontrar el n -vector \mathbf{x} de parámetros que da el "mejor ajuste" a la función del modelo $f(t, \mathbf{x})$,

$$\min_{\mathbf{x}} \sum_{i=1}^m (y_i - f(t_i, \mathbf{x}))^2$$

- ▶ El problema es **lineal** si la función f es una combinación lineal de las componentes de \mathbf{x}

$$f(t, \mathbf{x}) = x_1\phi_1(t) + x_2\phi_2(t) + \cdots + x_n\phi_n(t)$$

donde las funciones ϕ_j solo dependen de t

- ▶ \cong

El problema lineal se puede escribir matricialmente como $\mathbf{Ax} = \mathbf{b}$, con $a_{ij} = \phi_j(t_i)$ y $b_i = y_i$

Ajuste de datos

- ▶ Ajuste polinomial

$$f(t, \mathbf{x}) = x_1 + x_2 t + x_3 t^2 + \cdots + x_n t^{n-1}$$

es lineal, ya que el polinomio es lineal en sus coeficientes, aunque no lineal en la variable independiente t

- ▶ Suma de ajustes exponenciales

$$f(t, \mathbf{x}) = x_1 e^{x_2 t} + \cdots + x_{n-1} e^{x_n t}$$

es un ejemplo de problema no lineal

- ▶ Por ahora, consideraremos solo problemas de mínimos cuadrados lineales

Example: Data Fitting

- Ajustar un polinomio cuadrático a cinco puntos de datos da un problema de mínimos cuadrados lineales

$$\mathbf{Ax} = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ 1 & t_3 & t_3^2 \\ 1 & t_4 & t_4^2 \\ 1 & t_5 & t_5^2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{bmatrix} = \mathbf{b}$$

- La matriz cuyas columnas (o filas) son potencias sucesivas de la variable independiente se llama **matriz de Vandermonde**

Example,

- Para los datos

$$\begin{array}{c|ccccc} t & -1.0 & -0.5 & 0.0 & 0.5 & 1.0 \\ y & 1.0 & 0.5 & 0.0 & 0.5 & 2.0 \end{array}$$

El sistema lineal sobredeterminado de tamaño 5x3 es

$$\mathbf{Ax} = \begin{bmatrix} 1 & -1.0 & 1.0 \\ 1 & -0.5 & 0.25 \\ 1 & 0.0 & 0.0 \\ 1 & 0.5 & 0.25 \\ 1 & 1.0 & 1.0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 1.0 \\ 0.5 \\ 0.0 \\ 0.5 \\ 2.0 \end{bmatrix} = \mathbf{b}$$

- La solución, que veremos más adelante cómo calcularla es


$$\mathbf{x} = [0.086 \quad 0.40 \quad 1.4]^T$$

entonces el polinomio de aproximación es

$$p(t) = 0.086 + 0.4t + 1.4t^2$$

Example,

- ▶ La curva resultante y los puntos correspondientes a los datos originales se muestran en el gráfico



Existencia y unicidad

Existencia y unicidad

- ▶ El problema de mínimos cuadrados lineales $\mathbf{Ax} \cong \mathbf{b}$ siempre tiene solución
- ▶ La solución es *única* si, y sólo si, las columnas de \mathbf{A} son *linealmente independientes*, i.e., $\text{rank}(\mathbf{A}) = n$, con \mathbf{A} de tamaño $m \times n$
- ▶ Si $\text{rank}(\mathbf{A}) < n$, entonces \mathbf{A} es *de rango deficiente*, y la solución del ajuste por mínimos cuadrados no es único
- ▶ A partir de ahora, asumimos que \mathbf{A} tiene rango completo por columnas $\text{rank } n$

Normal Equations

- Para minimizar la norma euclidia al cuadrado del vector residual

$$\begin{aligned}\|\mathbf{r}\|_2^2 &= \mathbf{r}^T \mathbf{r} = (\mathbf{b} - \mathbf{Ax})^T (\mathbf{b} - \mathbf{Ax}) \\ &= \mathbf{b}^T \mathbf{b} - 2\mathbf{x}^T \mathbf{A}^T \mathbf{b} + \mathbf{x}^T \mathbf{A}^T \mathbf{Ax}\end{aligned}$$

Calculamos la derivada respecto \mathbf{x} y la igualamos a $\mathbf{0}$,

$$2\mathbf{A}^T \mathbf{Ax} - 2\mathbf{A}^T \mathbf{b} = \text{ecuaciones normales}$$

$$\mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b}$$

Ortogonalidad

- ▶ Los vectores \mathbf{v}_1 y \mathbf{v}_2 son *ortogonales* si el producto escalar, $\mathbf{v}_1^T \mathbf{v}_2 = 0$
- ▶ El espacio generados por las columnas de la matriz $\mathbf{A} \ m \times n$
- ▶ $\text{span}(\mathbf{A}) = \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^n\}$, tiene dimensión como mucho n
- ▶ Si $m > n$, \mathbf{b} generalmente no están en $\text{span}(\mathbf{A})$, por lo que no existe solución exacta de $\mathbf{Ax} = \mathbf{b}$


El vector $\mathbf{y} = \mathbf{Ax}$ está en $\text{span}(\mathbf{A})$ próximo a \mathbf{b} respecto la norm-2 cuando el vector residual $\mathbf{r} = \mathbf{b} - \mathbf{Ax}$ is *ortogonal* a $\text{span}(\mathbf{A})$,

$$\begin{aligned} 0 &= \mathbf{A}^T \mathbf{r} = \mathbf{A}^T (\mathbf{b} - \mathbf{Ax}) \\ \mathbf{A}^T \mathbf{Ax} &= \mathbf{A}^T \mathbf{b} \end{aligned}$$

De nuevo obtenemos las *ecuaciones normales*

Ortogonalidad

- La relación geométrica entre \mathbf{b} , \mathbf{r} , y $\text{span}(\mathbf{A})$ se muestra en el siguiente gráfico



Matrices ortogonales

- ▶ La matriz \mathbf{P} es **ortogonal** si es idempotente ($\mathbf{P}^2 = \mathbf{P}$) y simétrica ($\mathbf{P}^T = \mathbf{P}$)
- ▶ La matriz ortogonal y el complemento ortogonal $\text{span}(\mathbf{P})^\perp$ viene dado por $\mathbf{P}_\perp = \mathbf{I} - \mathbf{P}$
- ▶ Cualquier \mathbf{v} ,

$$\mathbf{v} = (\mathbf{P} + (\mathbf{I} - \mathbf{P})) \mathbf{v} = \mathbf{P}\mathbf{v} + \mathbf{P}_\perp \mathbf{v}$$

- ▶ El problema de mínimos cuadrados $\mathbf{A}\mathbf{x} \cong \mathbf{b}$, si $\text{rank}(\mathbf{A}) = n$, entonces

$$\mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$$

es la proyección ortogonal sobre el subespacio $\text{span}(\mathbf{A})$, y

$$\mathbf{b} = \mathbf{P}\mathbf{b} + \mathbf{P}_\perp \mathbf{b} = \mathbf{A}\mathbf{x} + (\mathbf{b} - \mathbf{A}\mathbf{x}) = \mathbf{y} + \mathbf{r}$$

Pseudoinversa y el Número de Condición

- ▶ La matriz rectangular $\mathbf{A} \ m \times n$ no tiene inversa en el sentido clásico
- ▶ Si $\text{rank}(\mathbf{A}) = n$, la **pseudoinversa** se define por

$$\mathbf{A}^+ = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$$

y el número de condición

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\|_2 \cdot \|\mathbf{A}^+\|_2$$

- ▶ By convention, $\text{cond}(\mathbf{A}) = \infty$ if $\text{rank}(\mathbf{A}) < n$
- ▶ Al igual que el número condición de una matriz cuadrada mide lo próxima que está a ser singular, en las matrices rectangulares mide lo próxima que está de tener rango deficienteJ
- ▶ La solución de mínimos cudrado $\mathbf{Ax} \cong \mathbf{b}$ viene dada por $\mathbf{x} = \mathbf{A}^+ \mathbf{b}$

Sensibilidad y condicionamiento

- ▶ La sensibilidad de la solución de mínimos cuadrado $\mathbf{Ax} \cong \mathbf{b}$ depende de \mathbf{b} así como de \mathbf{A}
- ▶ Se define el ángulo θ entre \mathbf{b} y $\mathbf{y} = \mathbf{Ax}$ por

$$\cos(\theta) = \frac{\|\mathbf{y}\|_2}{\|\mathbf{b}\|_2} = \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{b}\|_2}$$

- ▶ Si limitamos la perturbación en la solución $\mathbf{x}, \Delta\mathbf{x}$ pro la perturbación $\Delta\mathbf{b}$ en \mathbf{b} , viene dada por

$$\frac{\|\Delta\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \leq \text{cond}(\mathbf{A}) \frac{1}{\cos(\theta)} \frac{\|\Delta\mathbf{b}\|_2}{\|\mathbf{b}\|_2}$$

Sensibilidad y condicionamiento

- ▶ Análogamente, respecto a la perturbación \mathbf{E} en la matriz \mathbf{A} ,

$$\frac{\|\Delta \mathbf{x}\|_2}{\|\mathbf{x}\|_2} \lesssim ([\text{cond}(\mathbf{A})]^2 \tan(\theta) + \text{cond}(\mathbf{A})) \frac{\|\mathbf{E}\|_2}{\|\mathbf{A}\|_2}$$

- ▶ El número de condición de la solución de mínimos cuadrados del orden del $\text{cond}(\mathbf{A})$ si el residual es pequeño, pero puede elevarse al cuadrado o arbitrariamente peor para un residual grande

Resolviendo problemas de mínimos cuadrados

Método de las ecuaciones normales

- Si la matriz \mathbf{A} de tamaño $m \times n$ tiene rango n , entonces la matriz simétrica
- ▶ $\mathbf{A}^T \mathbf{A}$ de tamaño $n \times n$ es definida positiva, por lo tanto, la factorización de Cholesky

$$\mathbf{A}^T \mathbf{A} = \mathbf{L} \mathbf{L}^T$$

puede utilizarse para resolver el sistema de ecuaciones normales

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b}$$

que tiene la misma solución que el sistema de mínimos cuadrados $\mathbf{A} \mathbf{x}$

▶
$$\mathbf{b}$$

$$\cong$$

Las ecuaciones normales llevan involucradas las siguientes transformaciones

rectangular \longrightarrow cuadrada \longrightarrow triangular

que preservan la solución de mínimos cuadrados en principio, pero pueden no ser satisfactorias en aritmética de precisión finita.

Example: Método de las ecuaciones normales

- Para el ejemplo de ajuste de datos polinómicos dado anteriormente, el método de ecuaciones normales da

$$\begin{aligned} \mathbf{A}^T \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ -1.0 & -0.5 & 0.0 & 0.5 & 1.0 \\ 1.0 & 0.25 & 0.0 & 0.25 & 1.0 \end{bmatrix} \begin{bmatrix} 1 & -1.0 & 1.0 \\ 1 & -0.5 & 0.25 \\ 1 & 0.0 & 0.0 \\ 1 & 0.5 & 0.25 \\ 1 & 1.0 & 1.0 \end{bmatrix} \\ &= \begin{bmatrix} 5.0 & 0.0 & 2.5 \\ 0.0 & 2.5 & 0.0 \\ 2.5 & 0.0 & 2.125 \end{bmatrix}, \end{aligned}$$

$$\mathbf{A}^T \mathbf{b} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ -1.0 & -0.5 & 0.0 & 0.5 & 1.0 \\ 1.0 & 0.25 & 0.0 & 0.25 & 1.0 \end{bmatrix} \begin{bmatrix} 1.0 \\ 0.5 \\ 0.0 \\ 0.5 \\ 2.0 \end{bmatrix} = \begin{bmatrix} 4.0 \\ 1.0 \\ 3.25 \end{bmatrix}$$

Example,

- La factorización de Cholesky de la matriz simétrica definida positiva $\mathbf{A}^T \mathbf{A}$ da

$$\begin{aligned}\mathbf{A}^T \mathbf{A} &= \begin{bmatrix} 5.0 & 0.0 & 2.5 \\ 0.0 & 2.5 & 0.0 \\ 2.5 & 0.0 & 2.125 \end{bmatrix} \\ &= \begin{bmatrix} 2.236 & 0 & 0 \\ 0 & 1.581 & 0 \\ 1.118 & 0 & 0.935 \end{bmatrix} \begin{bmatrix} 2.236 & 0 & 1.118 \\ 0 & 1.581 & 0 \\ 0 & 0 & 0.935 \end{bmatrix} = \mathbf{L} \mathbf{L}^T\end{aligned}$$

- Resolviendo el sistema triangular $\mathbf{L} \mathbf{z} = \mathbf{A}^T \mathbf{b}$ por sustitución hacia atrás da $\mathbf{z} = \begin{bmatrix} 1.789 & 0.632 & 1.336 \end{bmatrix}^T$
- Resolviendo el sistema triangular superior $\mathbf{L}^T \mathbf{x} = \mathbf{z}$ da $\mathbf{x} = \begin{bmatrix} 0.086 & 0.400 & 1.429 \end{bmatrix}$

Deficiencias de las ecuaciones normales

- ▶ Cierta información puede perderse al calcular $\mathbf{A}^T \mathbf{A}$ y $\mathbf{A}^T \mathbf{b}$
- ▶ Por ejemplo, considera

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ \epsilon & 0 \\ 0 & \epsilon \end{bmatrix}$$

donde ϵ es un número positivo más pequeño que $\sqrt{\epsilon_{\text{mach}}}$

- ▶ Entonces en aritmética flotante

$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 1 + \epsilon^2 & 1 \\ 1 & 1 + \epsilon^2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

que es singular

- ▶ La sensibilidad de la solución también empeora, ya que

$$\text{cond}(\mathbf{A}^T \mathbf{A}) = [\text{cond}(\mathbf{A})]^2$$